

Apéndice: Manual Técnico

Práctica: Clustering Jerárquico mediante el método de Ward

1. Descripción general del sistema

El sistema implementado corresponde a la aplicación del algoritmo de **clustering jerárquico mediante el método de Ward** utilizando el lenguaje de programación Python y librerías especializadas para análisis de datos.

El objetivo principal del sistema es generar agrupaciones de estudiantes a partir de sus características, identificar estructuras internas en los datos y evaluar la correspondencia entre los clusters obtenidos y las clases reales de desempeño académico.

El sistema permite:

- Cargar y procesar el conjunto de datos desde archivos CSV.
- Generar clusters utilizando el método de Ward con distancia euclidiana.
- Construir y visualizar el dendrograma.
- Obtener particiones del dataset mediante diferentes cortes.
- Evaluar los resultados mediante matrices de confusión.
- Analizar la correspondencia entre clusters y clases reales.

2. Requerimientos de software

Para la ejecución del sistema se requiere:

- **Python 3.x**
- Librerías:
 - numpy
 - pandas
 - matplotlib
 - scipy
 - openpyxl

3. Estructura de los datos de entrada

El sistema utiliza el dataset *Higher Education Students Performance Evaluation*, el cual contiene registros de estudiantes con múltiples atributos.

3.1. Atributos

El conjunto de datos está compuesto por:

- Identificador del estudiante (`STUDENT ID`)
- Variables de comportamiento y desempeño (preguntas del cuestionario)
- Identificador del curso (`COURSE ID`)

3.2. Variable de clase

La variable `GRADE` representa el desempeño académico del estudiante y contiene 8 clases distintas.

Esta variable **no se utiliza durante el clustering**, pero se emplea posteriormente para evaluar los resultados.

4. Flujo funcional del sistema

El funcionamiento del sistema se organiza en las siguientes etapas:

4.1. Carga de datos

Los datos se cargan desde un archivo CSV utilizando la librería `pandas`. Se verifica la integridad del dataset y se identifican las variables relevantes.

4.2. Preprocesamiento

Se eliminan las variables `STUDENT ID` y `GRADE`, ya que no deben influir en la formación de los clusters.

Los datos restantes se convierten a formato numérico para su procesamiento.

4.3. Generación del clustering

Se utiliza la función `linkage()` de la librería `scipy`, aplicando el método de Ward y la distancia euclidiana.

Este proceso genera una matriz de enlace que contiene la información de las fusiones entre clusters.

4.4. Construcción del dendrograma

A partir de la matriz de enlace, se genera el dendrograma utilizando la función `dendrogram()`, permitiendo visualizar la estructura jerárquica de los datos.

4.5. Selección de clusters

Se utilizan diferentes valores de corte para obtener particiones del dataset con distinto número de grupos (por ejemplo, 4, 6 y 8 clusters).

Esto se realiza mediante la función `fcluster()`.

4.6. Asignación de etiquetas

Para evaluar el clustering, se utiliza el algoritmo húngaro, el cual permite asignar cada cluster a una clase real maximizando la correspondencia entre ambos.

4.7. Evaluación del modelo

Se construyen matrices de confusión comparando los clusters con las clases reales.

Se calculan métricas como la exactitud para evaluar el desempeño del sistema.

5. Resultados generados

El sistema produce los siguientes resultados:

- Dendrograma del clustering jerárquico.
- Dendrograma con líneas de corte.
- Archivos Excel con los grupos generados.
- Matriz de confusión multiclase.
- Matriz de confusión binaria.

6. Consideraciones técnicas

- El método de Ward requiere el uso de distancia euclidiana.
- El algoritmo es sensible a la escala de los datos.
- No se realizó estandarización por decisión experimental.
- El clustering no utiliza la variable de clase, por lo que no garantiza correspondencia con las etiquetas reales.

7. Limitaciones del sistema

- El clustering jerárquico es costoso computacionalmente para grandes volúmenes de datos.
- Es sensible a valores atípicos.
- No es un método de clasificación supervisada, por lo que su desempeño puede ser limitado al compararse con clases reales.