

# Apéndice: Marco Teórico

Práctica: Clustering Jerárquico mediante el método de Ward

## 1. Minería de datos y agrupamiento

La minería de datos es una disciplina que tiene como objetivo principal la extracción de conocimiento útil a partir de grandes volúmenes de información. Mediante el uso de técnicas estadísticas, matemáticas y de aprendizaje automático, se busca identificar patrones, relaciones y estructuras que permitan apoyar la toma de decisiones.

Dentro de este campo, el **agrupamiento** o clustering es una técnica de aprendizaje no supervisado que consiste en organizar los datos en grupos, de tal manera que los elementos dentro de un mismo grupo sean lo más similares posible entre sí y lo más diferentes posible respecto a otros grupos.

## 2. Aprendizaje no supervisado

El aprendizaje no supervisado es un enfoque en el cual el modelo no dispone de etiquetas de clase durante el entrenamiento. En lugar de aprender una relación entrada-salida, el objetivo es descubrir patrones ocultos en los datos.

En esta práctica, el algoritmo de clustering genera agrupaciones de estudiantes sin utilizar directamente la variable **GRADE**, permitiendo analizar si las estructuras encontradas coinciden con el desempeño académico real.

## 3. Clustering jerárquico

El **clustering jerárquico** es un método que construye una jerarquía de grupos a partir de los datos. Este enfoque puede representarse mediante un dendrograma, el cual muestra las fusiones o divisiones entre clusters.

Existen dos tipos principales:

- **Aglomerativo:** inicia con cada objeto como un cluster independiente y los fusiona progresivamente.
- **Divisivo:** inicia con un solo grupo y lo divide en subgrupos.

En esta práctica se utilizó el enfoque aglomerativo.

## 4. Método de Ward

El método de Ward es una técnica de clustering jerárquico que busca minimizar la varianza dentro de los clusters. En cada iteración, se selecciona la fusión de grupos que produce el menor incremento en la suma de errores cuadráticos.

Este enfoque permite generar clusters compactos y homogéneos desde un punto de vista estadístico.

## 5. Distancia euclidiana

Para medir la similitud entre los objetos, se utiliza la distancia euclidiana, definida como:

$$d(x, y) = \sqrt{\sum_{j=1}^m (x_j - y_j)^2} \quad (1)$$

donde:

- $x_j$  y  $y_j$  son los valores de los atributos.
- $m$  es el número total de variables.

## 6. Centroide

El centroide de un cluster es el punto que representa el promedio de todos los elementos que lo componen:

$$m_k = \frac{1}{n_k} \sum_{i=1}^{n_k} x_i \quad (2)$$

Este punto se utiliza como referencia para medir la dispersión interna del grupo.

## 7. Error intra-cluster

El error intra-cluster representa la suma de las distancias cuadradas de cada elemento respecto a su centroide:

$$E = \sum_{k=1}^n \sum_{i=1}^{n_k} (x_i - m_k)^2 \quad (3)$$

Un valor bajo de este error indica que los elementos dentro del cluster son similares entre sí.

## 8. Incremento de Ward

El criterio principal del método de Ward es minimizar el incremento en el error intra-cluster al fusionar dos grupos:

$$\Delta E_{pq} = \frac{n_p n_q}{n_p + n_q} \sum_{j=1}^m (m_j^p - m_j^q)^2 \quad (4)$$

donde:

- $n_p$  y  $n_q$  son los tamaños de los clusters.
- $m^p$  y  $m^q$  son sus centroides.

## 9. Dendrograma

El dendrograma es una representación gráfica del proceso de clustering jerárquico. En este diagrama:

- Cada hoja representa un objeto.
- Cada unión representa la fusión de dos clusters.
- La altura de la unión indica la distancia o incremento de varianza.

El número de grupos puede determinarse realizando un corte horizontal en el dendrograma.

## 10. Matriz de confusión

Aunque el clustering es un método no supervisado, es posible evaluar su desempeño comparando los clusters obtenidos con las clases reales mediante una matriz de confusión.

### 10.1. Matriz multiclase

Permite observar cómo se distribuyen las clases reales dentro de cada cluster.

### 10.2. Matriz binaria

Se puede construir utilizando el enfoque *one-vs-rest*, donde cada clase se evalúa contra las demás.

## 11. Métricas de evaluación

### 11.1. Exactitud (Accuracy)

$$Accuracy = \frac{\text{aciertos}}{\text{total de instancias}} \quad (5)$$

### 11.2. Precisión

$$Precision = \frac{TP}{TP + FP} \quad (6)$$

### 11.3. Sensibilidad

$$Recall = \frac{TP}{TP + FN} \quad (7)$$

## 11.4. Tasa de error

$$Error = 1 - Accuracy \tag{8}$$

Estas métricas permiten analizar qué tan bien los clusters representan las clases reales del conjunto de datos.