



Bénemerita Universidad Autónoma de Puebla

FACULTAD DE CIENCIAS DE LA COMPUTACIÓN

INGENIERIA EN TECNOLOGÍAS DE LA INFORMACIÓN

Materia

Mineria de Datos

Reporte

Práctica Clustering Jerarquico - Metodo de Ward

Profesor:

Pedro T. Vera

Integrantes:

Blanca Flor Visca Cocotzin
Christopher Aguilar Mendez
Angel Fernando Ruiz Vasquez

30 de abril del 2026

Índice

1. Introducción	3
2. Descripción del método de Ward	3
2.1. Fórmulas utilizadas	4
3. Procedimiento del algoritmo	4
4. Metodología	5
5. Resultados	5
5.1. Cortes del dendrograma	5
5.2. Matriz de confusión (8x8)	6
5.3. Matriz de confusión 2x2	6
6. Interpretación de resultados	6
7. Análisis del dendrograma	7
7.1. Dendrograma general	7
7.2. Interpretación estructural	8
7.3. Dendrograma con líneas de corte	8
7.4. Justificación de los cortes	9
7.5. Análisis del comportamiento del dendrograma	9
7.6. Relación con los resultados obtenidos	9
7.7. Conclusión del análisis	10
8. Conclusiones	10



Mineria de Datos

Práctica Ward

Blanca Flor Visca Cocotzin, Christopher Aguilar Mendez, Angel Fernando Ruiz Vasquez

30 de abril del 2026

Resumen

En esta práctica se aplicó el método de agrupamiento jerárquico de Ward, utilizando la base de datos *Higher Education Students Performance Evaluation*. Se realizó el análisis de similitud entre los estudiantes mediante la distancia euclidiana, generando un dendrograma que permitió identificar la estructura jerárquica de los datos y definir distintos niveles de agrupamiento. Posteriormente, se evaluó la correspondencia entre los clusters obtenidos y las clases reales mediante una matriz de confusión, calculando métricas como la exactitud. Finalmente, se analizaron los resultados obtenidos, observando las limitaciones del clustering no supervisado para representar correctamente las clases reales del problema.

1. Introducción

El agrupamiento jerárquico es una técnica de aprendizaje no supervisado utilizada para identificar estructuras naturales dentro de un conjunto de datos. A diferencia de los métodos supervisados, este enfoque no requiere etiquetas previas, lo que permite analizar la similitud entre objetos y organizarlos en grupos homogéneos.

En esta práctica se aplicó el método de Ward sobre la base de datos *Higher Education Students Performance Evaluation*, la cual contiene información académica y conductual de estudiantes. El objetivo principal fue identificar agrupaciones naturales y analizar en qué medida estas coinciden con la variable real de desempeño académico (GRADE).

2. Descripción del método de Ward

El método de Ward es un algoritmo de agrupamiento jerárquico aglomerativo que busca minimizar la varianza dentro de los grupos.

El proceso comienza considerando cada objeto como un cluster independiente y, en cada

iteración, fusiona aquellos grupos cuya unión genera el menor incremento en la suma de errores cuadráticos.

2.1. Fórmulas utilizadas

1) Distancia euclidiana:

$$d(x, y) = \sqrt{\sum_{j=1}^m (x_j - y_j)^2} \quad (1)$$

2) Centroide de un cluster:

$$m_k = \frac{1}{n_k} \sum_{i=1}^{n_k} x_i \quad (2)$$

3) Error intra-cluster:

$$E = \sum_{k=1}^n \sum_{i=1}^{n_k} (x_i - m_k)^2 \quad (3)$$

4) Incremento de Ward:

$$\Delta E_{pq} = \frac{n_p n_q}{n_p + n_q} \sum_{j=1}^m (m_j^p - m_j^q)^2 \quad (4)$$

3. Procedimiento del algoritmo

Para la aplicación del método de Ward se siguió el siguiente procedimiento:

1. Se consideró cada estudiante como un cluster individual.
2. Se calculó la matriz de distancias entre todos los pares de objetos.
3. Se identificaron los dos clusters más cercanos.
4. Se fusionaron dichos clusters en uno nuevo.

5. Se calculó el nuevo centroide del cluster resultante.
6. Se evaluó el incremento de varianza generado por la fusión.
7. Se actualizaron las distancias entre clusters.
8. El proceso se repitió hasta formar un solo grupo.

Este procedimiento genera una estructura jerárquica representada mediante un dendrograma, el cual permite visualizar las fusiones realizadas.

4. Metodología

Para el desarrollo de la práctica se siguieron las siguientes etapas:

1. **Carga de datos:** se utilizó el dataset de estudiantes con 145 instancias.
2. **Preprocesamiento:** se eliminaron las variables **STUDENT ID** y **GRADE**, ya que no deben influir en la formación de los clusters.
3. **Aplicación del algoritmo:** se utilizó el método de Ward con distancia euclidiana.
4. **Generación del dendrograma:** se representó la estructura jerárquica de los datos.
5. **Selección de cortes:** se analizaron diferentes alturas para obtener 4, 6 y 8 grupos.
6. **Asignación de etiquetas:** se utilizó el algoritmo húngaro para mapear clusters a clases reales.
7. **Evaluación:** se construyeron matrices de confusión para analizar el desempeño.

5. Resultados

5.1. Cortes del dendrograma

Se seleccionaron tres niveles de corte:

- 4 grupos ($h = 15.71$)
- 6 grupos ($h = 14.20$)
- 8 grupos ($h = 12.10$)

5.2. Matriz de confusión (8x8)

	P0	P1	P2	P3	P4	P5	P6	P7
R0	1	1	1	1	0	0	0	4
R1	4	11	4	5	0	5	0	6
R2	1	3	6	4	0	5	0	5
R3	3	2	1	4	0	6	2	3
R4	0	2	0	2	1	2	1	2
R5	1	4	0	2	0	8	0	2
R6	0	0	0	1	2	3	2	5
R7	0	2	0	1	3	1	3	7

Tabla 1: Matriz de confusión multiclase

Exactitud:

$$Accuracy = \frac{40}{145} = 27.59 \% \quad (5)$$

5.3. Matriz de confusión 2x2

	Pred Positivo	Pred Negativo
Real Positivo	40	105
Real Negativo	105	910

Tabla 2: Matriz binaria one-vs-rest

Exactitud binaria:

$$Accuracy = \frac{40 + 910}{1160} = 81.90 \% \quad (6)$$

6. Interpretación de resultados

La matriz 8x8 permite evaluar qué tan bien los clusters representan las clases reales. La baja exactitud (27.59 %) indica que los grupos generados no coinciden con las etiquetas originales.

Esto se debe a que:

- El clustering es un método no supervisado

- Existe solapamiento entre clases
- Las variables no separan claramente los grupos

Por otro lado, la matriz 2x2 muestra una alta exactitud (81.90 %), lo cual se debe al gran número de verdaderos negativos.

Esto ocurre porque cada estudiante pertenece a una sola clase, pero automáticamente no pertenece a las otras siete, generando una gran cantidad de aciertos en términos binarios.

7. Análisis del dendrograma

7.1. Dendrograma general




Figura 1: Dendrograma completo generado mediante el método de Ward

El dendrograma es una representación gráfica de la estructura jerárquica generada por el algoritmo de Ward. En este gráfico, cada hoja representa un estudiante, mientras que las uniones entre ramas indican la fusión de clusters.

El eje vertical representa la distancia de Ward, la cual corresponde al incremento en la varianza interna del cluster al realizar una fusión. Valores bajos indican que los elementos fusionados son muy similares, mientras que valores altos indican una menor similitud.

7.2. Interpretación estructural

Al analizar el dendrograma se pueden observar las siguientes características:

- Existen múltiples fusiones a baja altura, lo que indica la presencia de grupos pequeños de estudiantes con características similares.
- A medida que se asciende en el dendrograma, las fusiones requieren un mayor incremento de varianza, lo que sugiere que los grupos comienzan a ser más heterogéneos.
- Se observa un salto significativo en la altura de las últimas fusiones, lo cual indica que los clusters finales agrupan elementos con baja similitud.

7.3. Dendrograma con líneas de corte




Figura 2: Dendrograma con líneas de corte para diferentes valores de k

Para determinar el número de grupos, se realizaron cortes horizontales en el dendrograma en diferentes alturas:

- Corte A: 4 grupos ($h = 15.71$)
- Corte B: 6 grupos ($h = 14.20$)
- Corte C: 8 grupos ($h = 12.10$)

Cada corte define una partición distinta del conjunto de datos, donde todos los elementos conectados por debajo de la línea pertenecen al mismo cluster.

7.4. Justificación de los cortes

La selección de los valores de corte se realizó considerando los cambios en la altura del dendrograma:

- El corte en 4 grupos representa una visión global, donde los clusters son más grandes y generales.
- El corte en 6 grupos permite observar una estructura intermedia, donde los clusters comienzan a diferenciarse con mayor claridad.
- El corte en 8 grupos coincide con el número de clases reales del dataset (**GRADE**), lo cual permite comparar directamente el clustering con la clasificación real.

7.5. Análisis del comportamiento del dendrograma

El comportamiento observado en el dendrograma puede explicarse por las características del dataset:

- **Alta similitud entre estudiantes:** muchas fusiones ocurren a baja altura, lo que indica que existen múltiples estudiantes con perfiles similares.
- **Solapamiento entre clases:** las clases reales no están claramente separadas en el espacio de atributos, lo que provoca que los clusters no coincidan con las etiquetas originales.
- **Incrementos grandes en etapas finales:** las últimas fusiones presentan saltos importantes en la distancia de Ward, lo que indica que se están uniendo grupos poco similares, forzando la formación de clusters más grandes.

7.6. Relación con los resultados obtenidos

El análisis del dendrograma explica directamente los resultados de la matriz de confusión:

- La falta de separaciones claras en el dendrograma se traduce en una baja exactitud multiclase (27.59 %).
- La existencia de muchos grupos similares provoca que los clusters no correspondan a una sola clase, sino que mezclen varias.
- Esto confirma que el clustering jerárquico no logra replicar las clases reales del dataset.

7.7. Conclusión del análisis

El dendrograma permite visualizar que, aunque existen agrupaciones naturales en los datos, estas no coinciden con las clases reales de desempeño académico.

Esto se debe a que el método de Ward agrupa en función de similitud estructural y no en función de etiquetas, lo que evidencia una limitación del clustering cuando se utiliza como herramienta de clasificación.

8. Conclusiones

El método de Ward permitió identificar agrupaciones estructurales dentro de los datos, generando una representación jerárquica clara mediante el dendrograma.

Sin embargo, los resultados muestran que dichas agrupaciones no coinciden con las clases reales de desempeño académico, lo que evidencia una limitación del clustering no supervisado.

La diferencia entre la exactitud multiclase y la binaria resalta la importancia de seleccionar métricas adecuadas para la evaluación.

En conclusión, el clustering jerárquico es una herramienta útil para análisis exploratorio, pero no siempre es adecuado para tareas de clasificación directa.

Referencias

- [1] Yilmaz, N. and Sekeroglu, B. (2019). Higher Education Students Performance Evaluation Dataset. Recuperado de: <https://archive.ics.uci.edu/dataset/856/higher+education+students+performance+evaluation>. UCI Machine Learning Repository. DOI: 10.24432/C51G82. Fecha de consulta: 29/04/2026.